# Courbes de niveau de la fonction de coût et trajectoire de la descente de gradient

## Sommaire


- 1. Objet du document
- 2. Cadre mathématique
- 3. Lexique des termes employés
- 4. Lexique des symboles
- 5. Modèle de régression linéaire simple
- 6. Erreur ponctuelle, MSE et fonction de coût
- 7. Interprétation géométrique dans l'espace des paramètres
- 8. Développement complet de la fonction de coût
- 9. Gradient de la fonction de coût
- 10. Mini-cours sur la matrice hessienne
- 11. Forme des courbes de niveau
- 12. Inclinaison des ellipses
- 13. Allongement des ellipses
- 14. Minimum global et point optimal
- 15. Descente de gradient
- 16. Sens géométrique de la trajectoire
- 17. Construction d'un contour plot
- 18. Rôle du logarithme dans la représentation
- 19. Effet de la normalisation des données
- 20. Dé-normalisation des paramètres
- 21. Lecture scientifique du graphique obtenu
- 22. Formules à retenir


---

## 1. Objet du document

Présenter, dans le cadre de la régression linéaire simple, la construction mathématique d'un **contour plot** de la fonction de coût, puis l'interprétation de la **trajectoire de la descente de gradient** dans l'espace des paramètres.

Le graphique étudié ne représente pas les points du jeu de données dans le plan usuel $(x, y)$. Il représente la valeur de l'erreur globale du modèle dans le plan des paramètres $(\theta_0, \theta_1)$.

---

## 2. Cadre mathématique

Considérer un ensemble de données

$$\mathcal{D} = \{(x_1, y_1), (x_2, y_2), \ldots, (x_m, y_m)\}.$$

La variable $x$ désigne la variable explicative. La variable $y$ désigne la variable à prédire.

Le modèle linéaire étudié possède deux paramètres :

$$\theta_0 \quad \text{et} \quad \theta_1.$$

Le but de l'apprentissage consiste à déterminer des valeurs de $\theta_0$ et $\theta_1$ qui rendent le modèle aussi précis que possible sur les données disponibles.

---

## 3. Lexique des termes employés

| Terme | Définition |
|---|---|
| Régression linéaire simple | Méthode de modélisation dans laquelle la variable prédite est approchée par une fonction affine d'une seule variable explicative. |
| Paramètre | Quantité fixée par l'apprentissage et non connue à l'avance. Ici, $\theta_0$ et $\theta_1$ sont les paramètres du modèle. |
| Ordonnée à l'origine | Valeur prédite lorsque $x = 0$. Elle correspond à $\theta_0$. |
| Pente | Variation de la prédiction lorsque $x$ augmente d'une unité. Elle correspond à $\theta_1$. |
| Prédiction | Valeur produite par le modèle pour une observation donnée. |
| Erreur ponctuelle | Différence entre la valeur prédite et la valeur observée pour une observation. |
| Fonction de coût | Fonction qui associe à chaque couple de paramètres une erreur globale sur l'ensemble des données. |
| MSE | Abréviation de *Mean Squared Error*, c'est-à-dire moyenne des erreurs quadratiques. |
| Gradient | Vecteur formé des dérivées partielles de la fonction de coût. Il indique localement la direction de croissance la plus rapide. |
| Hessienne | Matrice des dérivées partielles secondes. Elle décrit la courbure locale de la fonction. |
| Courbe de niveau | Ensemble des points pour lesquels une fonction prend une valeur constante. |
| Contour plot | Représentation plane d'une fonction de deux variables à l'aide de courbes de niveau. |
| Minimum global | Point où la fonction atteint sa plus petite valeur sur tout son domaine. |

| Terme | Définition |
|---|---|
| Descente de gradient | Méthode itérative d'optimisation consistant à se déplacer dans la direction opposée au gradient. |
| Learning rate | Coefficient positif qui règle la taille du déplacement à chaque itération de la descente de gradient. |
| Convexité | Propriété géométrique assurant, dans ce contexte, l'absence de minima locaux parasites et l'existence d'un unique minimum global lorsque la hessienne est définie positive. |
| Normalisation | Transformation des données visant à ramener les valeurs dans une échelle plus homogène. |

---

## 4. Lexique des symboles

| Symbole | Définition |
|---|---|
| $\mathcal{D}$ | Ensemble des observations. |
| $m$ | Nombre total d'observations. |
| $(x_i, y_i)$ | $i$-ième observation. |
| $\theta_0$ | Ordonnée à l'origine du modèle. |
| $\theta_1$ | Pente du modèle. |
| $\theta = (\theta_0, \theta_1)$ | Vecteur des paramètres. |
| $h_\theta(x)$ | Prédiction du modèle pour l'entrée $x$. |
| $\hat{y}_i$ | Valeur prédite pour la $i$-ième observation. |
| $e_i$ | Erreur ponctuelle pour la $i$-ième observation. |
| $J(\theta_0, \theta_1)$ | Fonction de coût. |
| $\nabla J$ | Gradient de la fonction $J$. |
| $H$ | Matrice hessienne de $J$. |
| $\eta$ | Learning rate. |
| $\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$ | Moyenne des valeurs de $x$. |
| $\bar{y} = \frac{1}{m}\sum_{i=1}^{m} y_i$ | Moyenne des valeurs de $y$. |
| $\overline{x^2} = \frac{1}{m}\sum_{i=1}^{m} x_i^2$ | Moyenne des carrés des valeurs de $x$. |
| $\overline{xy} = \frac{1}{m}\sum_{i=1}^{m} x_i y_i$ | Moyenne des produits $x_i y_i$. |
| $(\theta_0^\star, \theta_1^\star)$ | Couple optimal — minimum global de la fonction de coût ($\star$ = optimal). |
| $\mathbb{R}$ | Ensemble des nombres réels. |
| $\mathbb{R}_{>0}$ | Ensemble des réels strictement positifs. |

---

## 5. Modèle de régression linéaire simple

Le modèle affine étudié est

$$h_\theta(x) = \theta_0 + \theta_1 x.$$

Pour l'observation $(x_i, y_i)$, la valeur prédite vaut

$$\hat{y}_i = h_\theta(x_i) = \theta_0 + \theta_1 x_i.$$

Le paramètre $\theta_0$ règle le décalage vertical de la droite. Le paramètre $\theta_1$ règle l'inclinaison de la droite.

---

## 6. Erreur ponctuelle, MSE et fonction de coût

### 6.1. Erreur ponctuelle

Pour chaque observation, définir l'erreur

$$e_i = h_\theta(x_i) - y_i = \theta_0 + \theta_1 x_i - y_i.$$

Cette erreur peut être positive, négative ou nulle.

### 6.2. Erreur quadratique moyenne

Afin d'éviter la compensation entre erreurs positives et erreurs négatives, considérer les carrés des erreurs :

$$e_i^2 = (\theta_0 + \theta_1 x_i - y_i)^2.$$

La moyenne de ces carrés est la MSE :

$$\mathrm{MSE}(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i)^2.$$

### 6.3. Fonction de coût

Introduire la fonction de coût usuelle :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i)^2.$$

Le facteur $\frac{1}{2}$ simplifie les dérivées. Il ne modifie pas la position du minimum.

La relation entre MSE et fonction de coût est

$$\mathrm{MSE} = 2J.$$

## 7. Interprétation géométrique dans l'espace des paramètres

La fonction de coût dépend de deux variables : $\theta_0$ et $\theta_1$.

Il devient donc possible d'interpréter $J$ comme une surface au-dessus du plan des paramètres :

$$(\theta_0, \theta_1) \longmapsto J(\theta_0, \theta_1).$$

Chaque point du plan $(\theta_0, \theta_1)$ correspond à une droite candidate.

Chaque hauteur au-dessus de ce point correspond au coût associé à cette droite.

Le contour plot constitue la projection plane de cette surface, obtenue en traçant les courbes

$$J(\theta_0, \theta_1) = c,$$

pour différentes constantes $c$.

## 8. Développement complet de la fonction de coût

Partir de

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i)^2.$$

Développer le carré :

$$(\theta_0 + \theta_1 x_i - y_i)^2 = \theta_0^2 + 2\theta_0\theta_1 x_i - 2\theta_0 y_i + \theta_1^2 x_i^2 - 2\theta_1 x_i y_i + y_i^2.$$

Remplacer dans la somme :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(\theta_0^2 + 2\theta_0\theta_1 x_i - 2\theta_0 y_i + \theta_1^2 x_i^2 - 2\theta_1 x_i y_i + y_i^2\right).$$

Utiliser la linéarité de la somme :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \left( \sum_{i=1}^{m} \theta_0^2 + \sum_{i=1}^{m} 2\theta_0\theta_1 x_i - \sum_{i=1}^{m} 2\theta_0 y_i + \sum_{i=1}^{m} \theta_1^2 x_i^2 - \sum_{i=1}^{m} 2\theta_1 x_i y_i + \sum_{i=1}^{m} y_i^2 \right).$$

Comme $\theta_0$ et $\theta_1$ ne dépendent pas de l'indice $i$, simplifier :

$$\sum_{i=1}^{m} \theta_0^2 = m\theta_0^2,$$

$$\sum_{i=1}^{m} 2\theta_0\theta_1 x_i = 2\theta_0\theta_1 \sum_{i=1}^{m} x_i,$$

$$\sum_{i=1}^{m} 2\theta_0 y_i = 2\theta_0 \sum_{i=1}^{m} y_i,$$

$$\sum_{i=1}^{m} \theta_1^2 x_i^2 = \theta_1^2 \sum_{i=1}^{m} x_i^2,$$

$$\sum_{i=1}^{m} 2\theta_1 x_i y_i = 2\theta_1 \sum_{i=1}^{m} x_i y_i.$$

Introduire les moyennes usuelles :

$$\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i, \qquad \bar{y} = \frac{1}{m}\sum_{i=1}^{m} y_i,$$

$$\overline{x^2} = \frac{1}{m}\sum_{i=1}^{m} x_i^2, \qquad \overline{xy} = \frac{1}{m}\sum_{i=1}^{m} x_i y_i, \qquad \overline{y^2} = \frac{1}{m}\sum_{i=1}^{m} y_i^2.$$

Obtenir finalement

$$J(\theta_0, \theta_1) = \frac{1}{2}\theta_0^2 + \theta_0\theta_1\bar{x} - \theta_0\bar{y} + \frac{1}{2}\theta_1^2\overline{x^2} - \theta_1\overline{xy} + \frac{1}{2}\overline{y^2}.$$

Cette écriture montre explicitement que $J$ est un polynôme de degré $2$ en $(\theta_0, \theta_1)$.

---

## 9. Gradient de la fonction de coût

Le gradient est le vecteur des dérivées partielles premières.

### 9.1. Dérivée partielle par rapport à $\theta_0$

À partir de

$$J(\theta_0, \theta_1) = \frac{1}{2m}\sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i)^2,$$

obtenir

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{2m}\sum_{i=1}^{m} 2(\theta_0 + \theta_1 x_i - y_i) = \frac{1}{m}\sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i).$$

### 9.2. Dérivée partielle par rapport à $\theta_1$

De même,

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{2m} \sum_{i=1}^{m} 2(\theta_0 + \theta_1 x_i - y_i) x_i = \frac{1}{m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i) x_i.$$

### 9.3. Écriture vectorielle du gradient

Ainsi,

$$\nabla J(\theta_0, \theta_1) = \left( \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \right).$$

Le gradient indique la direction locale de croissance la plus rapide de la fonction. La direction opposée correspond donc à une diminution locale de la fonction de coût.

---

## 10. Mini-cours sur la matrice hessienne

### 10.1. Définition générale

Pour une fonction de deux variables $f(u, v)$, la matrice hessienne est

$$H_f(u, v) = \begin{pmatrix} \frac{\partial^2 f}{\partial u^2} & \frac{\partial^2 f}{\partial u \partial v} \\ \frac{\partial^2 f}{\partial v \partial u} & \frac{\partial^2 f}{\partial v^2} \end{pmatrix}.$$

Elle rassemble toutes les dérivées partielles secondes. Elle décrit la courbure locale de la fonction.

### 10.2. Signification des dérivées secondes

- $\frac{\partial^2 f}{\partial u^2}$ mesure la courbure selon la direction $u$ ;
- $\frac{\partial^2 f}{\partial v^2}$ mesure la courbure selon la direction $v$ ;
- $\frac{\partial^2 f}{\partial u \partial v}$ mesure le couplage entre les deux directions.

### 10.3. Hessienne de la fonction de coût

À partir des dérivées premières, calculer les dérivées secondes :

$$\frac{\partial^2 J}{\partial \theta_0^2} = 1,$$

$$\frac{\partial^2 J}{\partial\theta_0\partial\theta_1} = \bar{x},$$

$$\frac{\partial^2 J}{\partial\theta_1\partial\theta_0} = \bar{x},$$

$$\frac{\partial^2 J}{\partial\theta_1^2} = \overline{x^2}.$$

Donc,

$$H = \begin{pmatrix} 1 & \bar{x} \\ \bar{x} & \overline{x^2} \end{pmatrix}.$$

### 10.4. Symétrie de la matrice

Les dérivées croisées sont égales :

$$\frac{\partial^2 J}{\partial\theta_0\partial\theta_1} = \frac{\partial^2 J}{\partial\theta_1\partial\theta_0}.$$

Cette propriété est classique pour les fonctions suffisamment régulières.

### 10.5. Rôle de la hessienne dans l'étude géométrique

La hessienne permet de répondre à trois questions essentielles :

1. la fonction est-elle convexe ;
2. les courbes de niveau sont-elles circulaires ou elliptiques ;
3. l'orientation et l'allongement des courbes dépendent-ils d'un couplage entre les variables.

### 10.6. Condition de convexité

Une matrice symétrique réelle est définie positive lorsque toutes ses directions présentent une courbure strictement positive.

Pour une matrice $2 \times 2$,

$$\begin{pmatrix} a & b \\ b & d \end{pmatrix},$$

une condition pratique de définition positive est

$$a > 0 \qquad \text{et} \qquad ad - b^2 > 0.$$

Ici,

$$a = 1, \qquad b = \bar{x}, \qquad d = \overline{x^2}.$$

Le déterminant vaut

$$\det(H) = \overline{x^2} - \bar{x}^2.$$

Or

$$\overline{x^2} - \bar{x}^2$$

est la variance empirique de $x$. Si les valeurs de $x$ ne sont pas toutes identiques, cette variance est strictement positive. Dans ce cas, la hessienne est définie positive.

### 10.7. Conséquence sur l'optimisation

Si la hessienne est définie positive, la fonction de coût est strictement convexe. Elle possède alors un unique minimum global.

---

## 11. Forme des courbes de niveau

Considérer une équation de niveau

$$J(\theta_0, \theta_1) = c.$$

Comme $J$ est une fonction quadratique en $(\theta_0, \theta_1)$, cette équation est une équation quadratique à deux variables. Dans le cas convexe précédent, elle décrit une ellipse.

Plus précisément, une fonction quadratique de la forme

$$q(u, v) = \frac{1}{2} \begin{pmatrix} u & v \end{pmatrix} A \begin{pmatrix} u \\ v \end{pmatrix} + \text{termes affines} + \text{constante},$$

avec $A$ symétrique définie positive, possède des courbes de niveau elliptiques.

Conséquence géométrique immédiate : les courbes de niveau de la fonction de coût sont des ellipses concentriques autour du point optimal $(\theta_0^\star, \theta_1^\star)$.

---

## 12. Inclinaison des ellipses

Dans l'expression développée de $J$, le terme

$$\theta_0 \theta_1 \bar{x}$$

est un terme croisé. Il exprime un couplage entre les variables $\theta_0$ et $\theta_1$.

Lorsqu'un tel terme croisé est présent, les axes principaux des courbes de niveau ne coïncident généralement pas avec les axes du repère $(\theta_0, \theta_1)$.

Si $\bar{x} = 0$, le terme croisé disparaît et les ellipses sont alignées avec les axes. Si $\bar{x} \neq 0$, elles sont généralement inclinées.

---

## 13. Allongement des ellipses

L'allongement dépend de l'intensité de la courbure selon les directions principales.

Si la courbure était identique dans toutes les directions, les courbes de niveau seraient circulaires. Ici, les courbures sont différentes, ce qui produit des ellipses plus ou moins étirées.

L'information est contenue dans les valeurs propres de la hessienne :

- une grande valeur propre correspond à une direction de courbure forte ;
- une petite valeur propre correspond à une direction de courbure faible.

Une forte différence entre les deux valeurs propres produit une vallée étroite et allongée.

---

## 14. Minimum global et point optimal

Le point optimal est le couple $(\theta_0^\star, \theta_1^\star)$ où la fonction de coût est minimale.

Ce point vérifie

$$\nabla J(\theta_0^\star, \theta_1^\star) = 0.$$

Comme la fonction est strictement convexe lorsque les $x_i$ ne sont pas tous égaux, ce point critique est l'unique minimum global.

Toutes les courbes de niveau sont donc centrées autour de ce point.

---

## 15. Descente de gradient

### 15.1. Principe

La descente de gradient construit une suite de paramètres

$$(\theta_0^{(0)}, \theta_1^{(0)}), (\theta_0^{(1)}, \theta_1^{(1)}), \ldots, (\theta_0^{(k)}, \theta_1^{(k)}), \ldots$$

par la règle de mise à jour

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \eta \, \frac{\partial J}{\partial \theta_0}(\theta_0^{(k)}, \theta_1^{(k)}),$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \eta \, \frac{\partial J}{\partial \theta_1}(\theta_0^{(k)}, \theta_1^{(k)}).$$

### 15.2. Forme explicite

En remplaçant les dérivées par leurs expressions,

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \eta \left[ \frac{1}{m} \sum_{i=1}^{m} \left( \theta_0^{(k)} + \theta_1^{(k)} x_i - y_i \right) \right],$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \eta \left[ \frac{1}{m} \sum_{i=1}^{m} \left( \theta_0^{(k)} + \theta_1^{(k)} x_i - y_i \right) x_i \right].$$

### 15.3. Rôle du learning rate

Le paramètre $\eta$ règle l'amplitude du déplacement.

- si $\eta$ est trop petit, la convergence est lente ;
- si $\eta$ est convenable, la convergence est stable ;
- si $\eta$ est trop grand, la trajectoire peut osciller ou diverger.

---

## 16. Sens géométrique de la trajectoire

Chaque itération de la descente de gradient fournit un nouveau point dans le plan $(\theta_0, \theta_1)$.

La suite de ces points constitue la trajectoire de l'algorithme.

Sur le contour plot :

- un point représente une droite candidate ;
- une courbe représente un ensemble de droites donnant le même coût ;
- la trajectoire montre comment l'algorithme se déplace d'une droite candidate à une autre jusqu'au voisinage du minimum global.

Dans une vallée très allongée, la trajectoire peut présenter un mouvement de zigzag.

---

## 17. Construction d'un contour plot

La construction numérique suit les étapes suivantes.

### Étape 1

Choisir un domaine du plan des paramètres :

$$\theta_0 \in [a, b], \qquad \theta_1 \in [c, d].$$

### Étape 2

Construire une grille régulière de points dans ce rectangle.

### Étape 3

Évaluer la fonction de coût $J(\theta_0, \theta_1)$ en chaque point de la grille.

### Étape 4

Sélectionner plusieurs valeurs de niveau

$$c_1, c_2, \ldots, c_p.$$

### Étape 5

Tracer les courbes

$$J(\theta_0, \theta_1) = c_1, \qquad J(\theta_0, \theta_1) = c_2, \qquad \ldots, \qquad J(\theta_0, \theta_1) = c_p.$$

### Étape 6

Superposer les points successifs de la descente de gradient.

Remarque : le choix du nombre de niveaux est un choix de visualisation. La géométrie générale de la surface de coût n'est pas arbitraire.

---

## 18. Rôle du logarithme dans la représentation

Il est fréquent de représenter non pas directement $J$, mais

$$\log(J + \varepsilon),$$

où $\varepsilon > 0$ est une très petite constante destinée à éviter le logarithme de zéro.

### 18.1. Justification mathématique

Le logarithme est strictement croissant sur $\mathbb{R}_{>0}$. Donc, si

$$J_1 < J_2,$$

alors

$$\log(J_1 + \varepsilon) < \log(J_2 + \varepsilon).$$

L'ordre des niveaux est conservé. Le minimum reste le minimum, et la structure générale des courbes de niveau est préservée.

### 18.2. Justification visuelle

Lorsque les coûts sont très dispersés, le logarithme compresse les grandes valeurs et étale davantage les petites valeurs. La zone proche du minimum devient alors plus lisible.

---

## 19. Effet de la normalisation des données

Supposer les transformations

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}, \qquad y' = \frac{y - y_{\min}}{y_{\max} - y_{\min}}.$$

La normalisation réduit les écarts d'échelle entre les variables.

Conséquences principales :

1. gradients généralement plus modérés ;
2. apprentissage plus stable ;
3. choix du learning rate plus simple ;
4. contour plot souvent plus lisible.

Sans normalisation, la vallée de la fonction de coût peut être extrêmement allongée, ce qui rend l'optimisation plus délicate.

---

## 20. Dé-normalisation des paramètres

Dans l'espace normalisé, le modèle s'écrit

$$y' = \theta'_0 + \theta'_1 x'.$$

Remplacer $x'$ et $y'$ par leurs définitions :

$$\frac{y - y_{\min}}{y_{\max} - y_{\min}} = \theta'_0 + \theta'_1 \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

Multiplier par $y_{\max} - y_{\min}$ :

$$y - y_{\min} = (y_{\max} - y_{\min})\theta'_0 + (y_{\max} - y_{\min})\theta'_1 \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

Développer :

$$y = y_{\min} + (y_{\max} - y_{\min})\theta'_0 - (y_{\max} - y_{\min})\theta'_1 \frac{x_{\min}}{x_{\max} - x_{\min}} + (y_{\max} - y_{\min})\theta'_1 \frac{x}{x_{\max} - x_{\min}}.$$

Comparer avec la forme

$$y = \theta_0 + \theta_1 x.$$

Obtenir alors

$$\theta_1 = \theta_1' \frac{y_{\max} - y_{\min}}{x_{\max} - x_{\min}},$$

$$\theta_0 = y_{\min} + (y_{\max} - y_{\min})\theta_0' - \theta_1 x_{\min}.$$

---

## 21. Lecture scientifique du graphique obtenu

Le contour plot accompagné de la trajectoire de la descente de gradient permet d'observer simultanément :

1. la structure quadratique de la fonction de coût ;
2. la position du minimum global ;
3. la géométrie de la vallée de coût ;
4. la qualité du choix du learning rate ;
5. la stabilité ou l'instabilité de la convergence.

### 21.1. Learning rate faible

La trajectoire progresse lentement vers le minimum.

### 21.2. Learning rate adapté

La trajectoire converge de manière stable vers le centre des ellipses.

### 21.3. Learning rate excessif

La trajectoire oscille de part et d'autre de la vallée ou diverge hors de la zone de stabilité.

---

## 22. Formules à retenir

### Modèle

$$h_\theta(x) = \theta_0 + \theta_1 x.$$

**Fonction de coût**

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i)^2.$$

**Gradient**

$$\frac{\partial J}{\partial \theta_0} = \frac{1}{m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i),$$

$$\frac{\partial J}{\partial \theta_1} = \frac{1}{m} \sum_{i=1}^{m} (\theta_0 + \theta_1 x_i - y_i) x_i.$$

**Hessienne**

$$H = \begin{pmatrix} 1 & \bar{x} \\ \bar{x} & \overline{x^2} \end{pmatrix}.$$

**Mise à jour de la descente de gradient**

$$\theta_0^{(k+1)} = \theta_0^{(k)} - \eta \frac{\partial J}{\partial \theta_0} (\theta_0^{(k)}, \theta_1^{(k)}),$$

$$\theta_1^{(k+1)} = \theta_1^{(k)} - \eta \frac{\partial J}{\partial \theta_1} (\theta_0^{(k)}, \theta_1^{(k)}).$$

**Point optimal**

$$\nabla J(\theta_0^\star, \theta_1^\star) = 0.$$

---